Продвинутое Машинное Обучение

Билеты к финальному экзамену

1. Надежность ML-экспериментов

Билет 1. Ожидаемый и эмпирический риск. Принцип ERM и связь выборочной оценки с качеством на новых данных.

Билет 2. Функции потерь и оптимальное предсказание. MSE, MAE, BCE и hinge loss: смысл и свойства оптимального предсказания.

Билет 3. Обобщение и оценка качества. Generalization gap и условия надежности тестовой оценки.

Билет 4. Утечки данных и point-in-time correctness. Временная доступность признаков и основные источники утечек.

Билет 5. Bias–variance trade-off. Смещение, дисперсия и шум; влияние сложности модели и регуляризации.

Билет 6. Интерполяционный порог и double descent. Зависимость риска от сложности до и после интерполяционного порога.

Билет 7. Кросс-валидация и проклятие победителя. K-fold, nested CV, шум оценок и правило одной стандартной ошибки.

2. Решающие деревья: CART

Билет 8. Дерево как класс функций. Кусочно-постоянные предсказания и осе-ориентированное разбиение пространства.

Билет 9. CART для классификации. Вероятности и класс в листе; Gini, энтропия и ошибка классификации.

Билет 10. CART для регрессии. Предсказание в листе и выбор разбиения при MSE и MAE.

Билет 11. Поиск порога и жадное построение. Кандидатные пороги, рекурсивный алгоритм и ограничения жадного выбора.

Билет 12. Регуляризация и обрезка дерева. Pre-pruning, cost-complexity pruning и компромисс между сложностью и обобщением.

Билет 13. Пропуски и смещение выбора признаков. Суррогатные сплиты, высокая кардинальность и variable selection bias.

Билет 14. Деревья условного вывода и ограничения CART. Выбор признака через permutation test; ограничения одиночного дерева.

3. Bagging, Random Forest и ExtraTrees

Билет 15. Bootstrap и bagging. Выборки с возвращением и агрегирование предсказаний базовых моделей.

Билет 16. Дисперсия среднего и корреляция моделей. Влияние числа моделей и их корреляции на снижение дисперсии.

Билет 17. Random Forest и случайный выбор признаков. Рандомизация признаков в узлах и роль max_features.

Билет 18. OOB-оценка качества. OOB-предсказания, доля OOB-объектов и ограничения такой оценки качества.

Билет 19. ExtraTrees и источники рандомизации. Случайные пороги и отличия ExtraTrees от bagging и Random Forest.

Билет 20. Дерево и лес в пространстве индикаторов. Линейность по индикаторам листьев и нелинейность в исходном пространстве.

4. Градиентный бустинг и AdaBoost

Билет 21. Аддитивная модель и пошаговое обучение. Начальное приближение, последовательное добавление моделей и отличие от bagging.

Билет 22. Псевдоостатки и функция потерь. Антиградиент по предсказаниям и его связь с остатками при квадратичной потере.

Билет 23. Функциональный градиентный спуск. Приближение антиградиента базовой моделью, line search и обобщение поправок.

Билет 24. Структура дерева и значения листьев в GBDT. Объединение объектов с похожими поправками и переоценка листьев по исходной потере.

Билет 25. Один раунд AdaBoost. Взвешенная ошибка, обновление весов объектов и голосование классификаторов.

Билет 26. AdaBoost, отступ и exponential loss. Роль margin, связь с экспоненциальной потерей и чувствительность к шуму.

5. Современные GBDT и feature engineering

Билет 27. Разложение Тейлора и Newton boosting. Первый и второй порядок: направление поправки, кривизна и веса объектов.

Билет 28. Ньютоновская поправка в листе. Роль градиента и гессиана; квадратичная и логистическая потери.

Билет 29. XGBoost: регуляризация, значение листа и score. Штрафы за сложность, сжатие значений листьев и оценка структуры дерева.

Билет 30. XGBoost: критерий Gain и поиск порогов. Смысл Gain, ограничения дочерних узлов и точный либо приближенный поиск порога.

Билет 31. Гистограммный поиск и рост дерева. Бины, статистики градиентов и гессианов; level-wise и leaf-wise рост.

Билет 32. LightGBM: GOSS и EFB. Сэмплирование по градиентам и объединение взаимоисключающих признаков.

Билет 33. Target encoding и ordered target statistics. Сглаживание, утечка таргета и кодирование по предшествующим объектам.

Билет 34. CatBoost: prediction shift и структура деревьев. Ordered boosting, симметричные деревья и комбинации категорий.

Билет 35. Выбор GBDT и пайплайн без утечек. Различия библиотек и корректная обработка признаков внутри пайплайна.

6. Подбор гиперпараметров и регуляризация

Билет 36. Задача HPO, grid search и random search. Стоимость поиска, эффективная размерность и покрытие пространства параметров.

Билет 37. Байесовская оптимизация и Gaussian Process. Суррогат, acquisition-функции и баланс exploration и exploitation.

Билет 38. Tree-structured Parzen Estimator. Хорошие и плохие испытания, отношение плотностей и условные параметры.

Билет 39. Successive Halving, Hyperband и ASHA. Распределение бюджета, ранний отбор и асинхронное продвижение испытаний.

Билет 40. Early stopping как регуляризация. Остановка модели и прунинг испытаний; связь с L2-регуляризацией.

Билет 41. Гиперпараметры регуляризации GBDT. Емкость деревьев, learning rate, число итераций, сэмплирование и явные штрафы.

Билет 42. Optuna и воспроизводимость экспериментов. Define-by-run, роли sampler и pruner, трекинг и воспроизводимость.

7. Интерпретируемость моделей

Билет 43. Классификация методов интерпретации. Ante-hoc и post-hoc, локальные и глобальные, специфичные и универсальные методы.

Билет 44. Интерпретация по определению. Коэффициенты линейной и логистической моделей, наивный Байес и ограничения интерпретации.

Билет 45. Деревья и impurity-based importance. Маршрут объекта, глобальная важность признаков и ограничения MDI.

Билет 46. ICE и PDP. Индивидуальные зависимости и их усреднение; скрытые разнонаправленные эффекты.

Билет 47. ALE и коррелированные признаки. Локальные эффекты, нереалистичные комбинации и выбор графического метода.

Билет 48. Permutation importance. Изменение качества при перестановке, устойчивость оценки и корреляция признаков.

Билет 49. SHAP и LIME. Значения Шепли, чтение SHAP-графиков и локальная суррогатная модель LIME.

8. Калибровка, неопределенность и выбор порога

Билет 50. Калибровка и разделяющая способность. Групповой смысл калибровки, отличие от AUC и диаграмма надежности.

Билет 51. ECE, Brier score и log loss. Оценка калибровки, собственные метрики и компоненты разложения Brier.

Билет 52. Методы калибровки. Платт, изотоническая и beta-калибровка; идея temperature scaling и монотонность.

Билет 53. Данные для калибровки и дисбаланс классов. Отдельная выборка или CV; влияние весов классов и ресэмплинга.

Билет 54. Алеаторная и эпистемическая неопределенность. Шум задачи, незнание модели, ансамблевый разброс и отказ от ответа.

Билет 55. Conformal prediction. Калибровочный скор, множество исходов и смысл гарантии покрытия.

Билет 56. Порог решения и фиксированный top-k. Стоимость ошибок, условия оптимальности порога 0,5 и ограничение объема решений.

Билет 57. Калибровка по группам и справедливость. Групповая калибровка, равенство долей ошибок и конфликт требований.