

Продвинутое машинное обучение

Лекция 1: Введение. Надежность ML-экспериментов

Автор курса: Лапшина Анастасия (University of Maryland, College Park, ВШЭ)

Часть 0. Введение в курс, знакомство, повторение пройденного

Знакомство и ожидания от курса



План курса и формула оценки

8 лекций, 8 семинаров, 2 промежуточных теста, 3 домашних задания

1 **Введение. Надежность ML-экспериментов**

2 CART: Classification and Regression Trees

3 Bagging / RF / ExtraTrees

4 Gradient Boosting

5 Современные GBDT и feature engineering

6 HPO и регуляризация

7 Интерпретируемость: основные методы оценки важности признаков для ML моделей

8 Калибровка, неопределенность и выбор порога

Формула оценки: $0,5 \times \text{ДЗ} + 0,1 \times \text{ПТ1} + 0,1 \times \text{ПТ2} + 0,3 \times \text{ФЭ}$

ДЗ - средняя оценка за домашние задания, ПТ - промежуточные тесты, ФЭ - оценка за финальный экзамен

* Если $\text{ДЗ} \geq 6$ и $\text{ПТ1} \geq 6$ и $\text{ПТ2} \geq 6$, то $\min\left(7; \frac{0,5 \cdot \text{ДЗ} + 0,2 \cdot \text{ПТ}}{0,7}\right)$

Мини-квиз

Вопрос №1

Антифрод-модель показала ассигасу **99,2%** на тесте. Доля мошеннических транзакций в данных **0,8%**. Что можно сказать о качестве модели?

- А. Модель отличная
- Б. Ничего нельзя
- В. Модель переобучена
- Г. Модель требует дальнейшего обучения

Вопрос №2

Все предсказанные моделью вероятности возвели в квадрат: $p \rightarrow p^2$. Тестовая выборка та же. Что произойдёт с ROC-AUC?

- А. Уменьшится: вероятности стали дальше от истины
- Б. Увеличится: уверенные предсказания усилились
- В. Не изменится
- Г. Зависит от данных

Вопрос со звёздочкой ко второму вопросу: а что тогда сломается? Почему?

Вопрос №3

Для каких моделей масштабирование признаков принципиально?

- А. Решающее дерево и случайный лес
- Б. kNN и линейная регрессия с L2-регуляризацией
- В. Для всех перечисленных одинаково важно
- Г. Ни для каких, если все признаки числовые

Вопрос №4

Что происходит с моделью kNN при увеличении числа соседей k ?

- А. Bias растёт, variance падает
- Б. Bias падает, variance растёт
- В. Растут оба
- Г. Падают оба

Вопрос №5

Из 10 000 признаков отобрали 100 с наибольшей корреляцией с таргетом по всему датасету. Затем разбили на train/test и прогнали кросс-валидацию. Оценка качества честная?

- А. Да: отбор признаков не является обучением модели
- Б. Нет: отбор уже посмотрел на таргет теста, оценка завышена
- В. Да, если признаков изначально было немного
- Г. Нет, но только когда признаков больше, чем объектов

Вопрос №6

На обучении loss ниже, чем на тесте. Это всегда переобучение?

- А. Да, по определению
- Б. Нет: небольшой разрыв - это нормально
- В. Переобучение только если разрыв больше 10 %
- Г. Да, если модель линейная

Часть 1. Ожидаемый и эмпирический риск

Обозначения

$\mathcal{X}$ — пространство признаков

$\mathcal{Y}$ — пространство таргетов

P — истинное распределение на $\mathcal{X} \times \mathcal{Y}$

$f \in \mathcal{F}$ — модель из класса моделей

$\hat{f}$ — выбранная (обученная) модель

$(x_i, y_i)_{i=1}^n$ — наблюдаемая выборка

$\ell(f(x), y)$ — loss на одном объекте

$A \subseteq \{1, \dots, n\}$ — индексное множество объектов

Ожидаемый и эмпирический риск

Мы хотим модель, которая хорошо работает на всех возможных новых данных, но видим только конечную выборку. Что делать?

При обучении выбираем модель, минимизирующую эмпирический риск на train-части данных:

$$\hat{f} \in \arg \min_{f \in \mathcal{F}} \hat{R}_{\text{train}}(f)$$

Это задача Empirical Risk Minimization: истинный риск посчитать нельзя (почему?), поэтому минимизируем его выборочную оценку и надеемся, что она близка к истине.

Что такое риск?

Риск определяется как математическое ожидание функции потерь по истинному распределению данных:

$$R_P(f) = \mathbb{E}_{(x,y) \sim P}[\ell(f(x), y)] = \int_{\mathcal{X} \times \mathcal{Y}} \ell(f(x), y) dP(x, y)$$

- Распределение P неизвестно - интеграл посчитать нельзя, можно только оценить по выборке
- Риск зависит и от модели f , и от выбранной функции потерь ℓ

Эмпирический риск

Для любого индексного подмножества $A \subseteq \{1, \dots, n\}$ определим эмпирический риск на подвыборке A :

$$\hat{R}_A(f) = \frac{1}{|A|} \sum_{i \in A} \ell(f(x_i), y_i)$$

$$\hat{R}_{\text{train}}(f) = \frac{1}{|A_{\text{train}}|} \sum_{i \in A_{\text{train}}} \ell(f(x_i), y_i),$$

$$\hat{R}_{\text{val}}(f) = \frac{1}{|A_{\text{val}}|} \sum_{i \in A_{\text{val}}} \ell(f(x_i), y_i),$$

$$\hat{R}_{\text{test}}(f) = \frac{1}{|A_{\text{test}}|} \sum_{i \in A_{\text{test}}} \ell(f(x_i), y_i)$$

Это **выборочное** приближение **ожидаемого** (expected) риска

Примеры функций потерь

MSE - квадратичная потеря , **MAE - абсолютная потеря** регрессия

$$\ell_{\text{MSE}}(f(x), y) = (f(x) - y)^2 \qquad \ell_{\text{MAE}}(f(x), y) = |f(x) - y|$$

BCE - бинарная кросс-энтропия бинарная классификация

$$\ell_{\text{BCE}}(f(x), y) = -\left[y \log f(x) + (1 - y) \log (1 - f(x)) \right], \quad y \in \{0, 1\}$$

Hinge loss SVM, margin-based классификация

$$\ell_{\text{hinge}}(f(x), y) = \max(0, 1 - yf(x)), \quad y \in \{-1, +1\}$$

Что минимизирует каждая функция потерь

Каждая функция потерь задаёт, какую характеристику условного распределения $P(Y | X = x)$ восстанавливает оптимальная модель:



$$\ell_{\text{MSE}} \implies f^*(x) = \mathbb{E}[Y | X = x]$$

$$\ell_{\text{MAE}} \implies f^*(x) = \text{median}(Y | X = x)$$

$$\ell_{\text{BCE}} \implies f^*(x) = \mathbb{P}(Y = 1 | X = x)$$

Вопрос: восстанавливает ли Hinge Loss корректную вероятность класса данного объекта?

Про Hinge Loss: кейс с пенальти



Generalization gap

$$\text{Gap}(\hat{f}) = R_P(\hat{f}) - \hat{R}_{\text{train}}(\hat{f})$$

- 1 **Эмпирический риск** на train - то, что мы можем посчитать. Его модель и минимизирует при обучении:

$$\hat{R}_{\text{train}}(f) = \frac{1}{|A_{\text{train}}|} \sum_{i \in A_{\text{train}}} \ell(f(x_i), y_i)$$

- 2 **Истинный риск** - реальная ошибка модели на новых данных из распределения $P(X, Y)$. Напрямую нам она неизвестна:

$$R_P(f) = \mathbb{E}_{(X,Y) \sim P} [\ell(f(X), Y)] = \int_{\mathcal{X} \times \mathcal{Y}} \ell(f(x), y) dP(x, y) = \int_{\mathcal{X}} \int_{\mathcal{Y}} \ell(f(x), y) p(x, y) dy dx$$

Generalization gap

- 3 На практике используем test-risk как приближение истинного риска*:

$$\hat{R}_{\text{test}}(f) = \frac{1}{n_{\text{test}}} \sum_{i \in A_{\text{test}}} \ell(f(x_i), y_i)$$


Поэтому на практике **generalization gap** оценивают как:

$$\text{Gap}(\hat{f}) \approx \hat{R}_{\text{test}}(\hat{f}) - \hat{R}_{\text{train}}(\hat{f})$$

* Когда R_{test} можно считать приближением истинного риска?

- 1 Тест не участвовал в обучении - модель его не видела, НРО по нему не проводили
- 2 Test set отражает реальный сценарий применения: i.i.d. в статических задачах, temporal / PIT split - в задачах со временем
- 3 Размер теста достаточно большой, иначе оценка качества шумная и имеет высокую дисперсию

PIT correctness



PIT correctness

$$H_u = [(i_1, t_1), (i_2, t_2), \dots, (i_m, t_m)]$$

полная история пользователя u : пары «айтем — момент времени»

$$H_u^{\leq t} = \{(i_k, t_k) : t_k \leq t\}$$

часть истории, доступная до момента t (cutoff time)

$$x_u(t) = \varphi(H_u^{\leq t})$$

признаки формируются только из доступной части истории

$$y_{u,i}(t) = 1\{\exists \text{ взаимодействие с айтемом } i \text{ в } (t, t + \Delta]\}$$

таргет для пары (user, item) в будущем окне $(t, t + \Delta]$

✗ Некорректно

$$\tilde{x}_u(t) = \varphi(H_u^{\leq T}), \quad T > t$$

Признаки используют информацию после момента t - возникает временная утечка (leakage).

Часть 2. Bias-variance tradeoff

Bias-variance tradeoff

✓ Split построен корректно

✓ Leakage нет, PIT соблюден

✓ Test set достаточно большой



...но gap всё равно остался. Почему?



overfitting → bias-variance

Bias & variance



Bias


систематическая ошибка модели

Насколько в среднем предсказание отклоняется от истинного значения

$$\text{Bias}^2 = \left(\mathbb{E}[\hat{f}(x)] - f^*(x) \right)^2$$

Высокий bias → underfitting

модель слишком проста, не улавливает структуру данных



Variance

чувствительность к выборке


Насколько сильно меняется модель при смене обучающей выборки

$$\text{Var} = \mathbb{E} \left[\left(\hat{f}(x) - \mathbb{E}[\hat{f}(x)] \right)^2 \right]$$

Высокий variance → overfitting

модель слишком сложна, запоминает шум конкретной выборки

Bias-variance tradeoff



Что часто происходит с ростом сложности модели

для вложенных классов и точного ERM train-риск не возрастает:

$$\hat{R}_{\text{train}}(\hat{f}) \downarrow$$

но после оптимальной точки:

$$\hat{R}_{\text{test}}(\hat{f}) \uparrow$$

и разница между ними тоже растёт:

$$\hat{R}_{\text{test}}(\hat{f}) - \hat{R}_{\text{train}}(\hat{f}) \uparrow$$

Слева — высокий bias и низкий variance, справа — наоборот.

Декомпозиция ошибки

Постановка задачи

$$Y = f(x_0) + \varepsilon, \quad \mathbb{E}[\varepsilon] = 0, \quad \text{Var}(\varepsilon) = \sigma_\varepsilon^2 \quad \text{Err}(x_0) = \mathbb{E}\left[(Y - \hat{f}(x_0))^2 \mid X = x_0\right]$$

1 Прибавим и вычтем $\mathbb{E}[\hat{f}(x_0)]$

$$Y - \hat{f}(x_0) = \underbrace{\varepsilon}_{\text{шум}} + \underbrace{(f(x_0) - \mathbb{E}[\hat{f}(x_0)])}_{\text{смещение (константа)}} + \underbrace{(\mathbb{E}[\hat{f}(x_0)] - \hat{f}(x_0))}_{\text{разброс (центрирован)}}$$

2 Переобозначим слагаемые и возведём сумму в квадрат

$$a = \varepsilon, \quad b = f(x_0) - \mathbb{E}[\hat{f}(x_0)], \quad c = \mathbb{E}[\hat{f}(x_0)] - \hat{f}(x_0)$$

$$\text{Err}(x_0) = \mathbb{E}[(a + b + c)^2] = \mathbb{E}[a^2] + b^2 + \mathbb{E}[c^2] + \underbrace{2\mathbb{E}[ab] + 2\mathbb{E}[ac] + 2\mathbb{E}[bc]}_{\text{три кросс-члена}}$$

Декомпозиция ошибки

$$\mathbb{E}[2ab] = 2b \mathbb{E}[\varepsilon] = 0$$

$$\mathbb{E}[2ac] = 2 \mathbb{E}[\varepsilon] \mathbb{E}[c] = 0$$

$$\mathbb{E}[2bc] = 2b \mathbb{E}[c] = 0$$



Остаются три квадрата

$$\mathbb{E}[a^2] = \sigma_\varepsilon^2$$

$$b^2 = (\mathbb{E}[\hat{f}(x_0)] - f(x_0))^2 = \text{Bias}^2(\hat{f}(x_0))$$

$$\mathbb{E}[c^2] = \mathbb{E}[(\hat{f}(x_0) - \mathbb{E}[\hat{f}(x_0)])^2] = \text{Var}(\hat{f}(x_0))$$

неустраняемый шум


систематическая ошибка

чувствительность к выборке




$$\text{Err}(x_0) = \sigma_\varepsilon^2 + \text{Bias}^2(\hat{f}(x_0)) + \text{Var}(\hat{f}(x_0))$$

То же разложение геометрически



После регуляризации проиграли в смещении, но выиграли в разбросе

На примерах моделей



Модель	Усложнение модели	Bias	Variance
kNN	$k \downarrow$ (меньше соседей)	$\downarrow$	$\uparrow$
Linear regression	$p \uparrow$ (больше признаков)	$\downarrow$	$\uparrow$
Decision tree	depth $\uparrow$, leaves $\uparrow$	$\downarrow$	$\uparrow$
Bagging	$B \uparrow$ (больше моделей)	$\approx$	$\downarrow$
Boosting	$M \uparrow$ (больше моделей)	$\downarrow$	$\uparrow$

* Для boosting рост variance с числом моделей - упрощение: при малом learning rate он часто почти не растёт. Подробнее обсудим в лекции 4


Интерполяционный порог

Классическая U кривая предполагает, что дальше рост сложности только вредит. Но у сильно параметризованных моделей (Deep Double Descent) за интерполяционным порогом риск падает снова.



Часть 3. Кросс-валидация

K-fold кросс-валидация




После того как каждый фолд выступил в роли валидации, усредним полученные оценки:

$$\hat{R}_{CV}^{(K)} = \frac{1}{K} \sum_{k=1}^K \hat{R}_{A_k}(\hat{f}^{(-k)})$$

Вопрос: как называется кросс-валидация при $K=n$?

Насколько надёжна сама CV-оценка


- 1 Если бы CV идеально оценивала true error, серые точки лежали бы на диагонали (но они разбросаны).
- 2 Заявленный 90%-й наивный доверительный интервал (зеленые линии) должен покрывать примерно 90% реальных CV-оценок: зелёные границы должны быть близки к красным (фактические 5% и 95% разброса в симуляции).
- 3 Но зелёные границы слишком узкие (интервал недооценивает неопределённость).



Проклятие победителя

Конфигурацию гиперпараметров выбираем по минимуму CV-оценки:

$$\hat{\lambda} \in \arg \min_{\lambda \in \Lambda} \widehat{R}_{CV}(\lambda)$$




Каждая оценка шумная, а мы всегда берём самую низкую - так выбирается не лучшая конфигурация, а самая удачливая, и её оценка систематически ниже истины (в реальности мы видим только белые точки).

Как с этим бороться

Правило одной стандартной ошибки


берём самую простую модель из тех, что статистически неотличимы от лучшей



Nested cross-validation

λ подбирается заново внутри каждого внешнего фолда, поэтому тест не участвовал ни в чём

внешний цикл



обучение



эти четыре блока делим ещё раз

внутренний цикл — здесь выбираем λ



...и так по всем внешним блокам

Часть 4. Плохие практики

Плохие практики: масштаб проблемы

Field	Paper	Number of papers reviewed Number of papers with pitfalls [L1.1] No test set [L1.2] Pre-proc. on train-test [L1.3] Feature sel. on train-test [L1.4] Duplicates [L2.1] Illegitimate features [L2.2] Temporal leakage [L3.1] Non-ind. b/w train-test [L3.2] Sampling bias Comput. reproducibility issues Data quality issues Metric choice issues Standard dataset used?										
Medicine	Bouwmeester et al. (2012)	71	27	o							o	
Neuroimaging	Whelan & Garavan (2014)	–	14	o		o						
Bioinformatics	Blagus & Lusa (2015)	–	6		o							
Autism Diagnostics	Bone et al. (2015)	–	3			o			o	o	o	
Nutrition Research	Ivanescu et al. (2016)	–	4	o						o	o	
Software Eng.	Tu et al. (2018)	58	11				o		o	o	o	
Toxicology	Alves et al. (2019)	–	1			o			o	o		
Clinical Epidem.	Christodoulou et al. (2019)	71	48			o				o		
Satellite Imaging	Nalepa et al. (2019)	17	17				o			o	o	
Tractography	Poulin et al. (2019)	4	2	o					o	o	o	
Brain-computer Int.	Nakanishi et al. (2020)	–	1	o							o	
Histopathology	Oner et al. (2020)	–	1					o				
Neuropsychiatry	Poldrack et al. (2020)	100	53	o	o					o	o	
Neuroimaging	Ahmed et al. (2021)	–	1				o					
Neuroimaging	Li et al. (2021)	122	18				o					
IT Operations	Lyu et al. (2021)	9	3				o				o	
Medicine	Filho et al. (2021)	–	1			o						
Radiology	Roberts et al. (2021)	62	16	o		o			o	o	o	
Neuropsychiatry	Shim et al. (2021)	–	1			o				o		
Medicine	Vandewiele et al. (2021)	24	21			o		o	o	o	o	
Computer Security	Arp et al. (2022)	30	22	o	o	o	o	o	o	o	o	
Genomics	Barnett et al. (2022)	41	23		o					o		

22

исследования в 17 областях
применения ML

294

статьи с выявленными ML-pitfalls


Плохие практики: утечка через соседей

- А и В похожи, потому что взаимодействовали с одними и теми же айтемами.


- В и С тоже похожи по общим айтемам.

- Но С появляется позже А.

- **Значит, при предсказании для А модель может использовать будущие взаимодействия.**



(a) User-item interaction along global timeline.



A	1...1	?			
B	1...1		1...1	?	
C			1...1		?

ИСТОЧНИКИ

1. Hastie, Tibshirani, Friedman — The Elements of Statistical Learning, 2009.
2. Shalev-Shwartz, Ben-David — Understanding Machine Learning, 2014.
3. Bates, Hastie, Tibshirani — Cross-Validation: What Does It Estimate and How Well Does It Do It?, 2024.
4. Bengio, Grandvalet — No Unbiased Estimator of the Variance of K-Fold Cross-Validation, 2004.
5. Belkin et al. — Reconciling Modern ML Practice and the Bias–Variance Trade-Off, 2019.
6. Bouthillier et al. — Accounting for Variance in Machine Learning Benchmarks, 2021.
7. Dwork et al. — The Reusable Holdout, 2015.
8. Blum, Hardt — The Ladder, 2015.
9. Kapoor, Narayanan — Leakage and the Reproducibility Crisis in ML-Based Science, 2023.
10. Ji et al. — A Critical Study on Data Leakage in Recommender System Offline Evaluation, 2023.
11. Kunitsyn — Частые ловушки в экспериментах машинного обучения, 2025.
12. Silpa — Point-in-Time Correctness: How to Prevent Time Travel in ML Data.