# Учет категориальных признаков

Продвинутое Машинное Обучение, ФКН ВШЭ, 2026

## Как разделить категории

Для категориального признака дерево выбирает две группы: категории из первой отправляет влево, из второй — вправо. Например, для признака “город” одна группа может содержать Москву и Казань, а другая — остальные города.

Если у признака $q$ категорий, непустых разбиений на две группы будет

$$2^{q-1} - 1.$$

Перестановка левой и правой групп не считается новым вариантом. При большом $q$ полный перебор становится дорогим.

## Бинарная классификация

Для каждой категории $u$ считаем **долю положительного класса** среди объектов, попавших в текущий узел $m$:

$$p_m(u) = \frac{1}{N_m(u)} \sum_{i \in I_m(u)} \mathbf{1}\{y_i = +1\}.$$

Здесь $I_m(u)$ — индексы объектов с категорией $u$ в этом узле, а $N_m(u)$ — их количество. Индикатор равен 1 для положительного класса и 0 для отрицательного.

Сортируем категории по этой доле. Например:

| Категория | $A$ | $C$ | $B$ | $D$ |
|---|---|---|---|---|
| Доля класса +1 | 0,10 | 0,20 | 0,70 | 0,90 |

Теперь проверяем только границы в полученном порядке:

$$\{A\} \mid \{C, B, D\}, \quad \{A, C\} \mid \{B, D\}, \quad \{A, C, B\} \mid \{D\}.$$

Выбираем разбиение с наибольшим уменьшением неоднородности по Джини или энтропии. Для этих критериев среди $q - 1$ границ есть оптимальное разбиение из полного перебора.

## Регрессия с MSE

Вместо доли положительного класса считаем **средний ответ** для каждой категории:

$$\bar{y}_m(u) = \frac{1}{N_m(u)} \sum_{i \in I_m(u)} y_i.$$

Сортируем категории по этому среднему, проверяем $q - 1$ границ и выбираем разбиение с наибольшим уменьшением суммы квадратов ошибок. Такой поиск также дает оптимальное разбиение на две группы.

**Важно:** порядок строится по обучающим объектам **текущего узла**, а не по произвольным номерам категорий. В разных узлах он может быть разным.