Гистограммы, Gain и GOSS

1. Вычисляем производные

Для каждого объекта при текущем прогнозе $a_i = F_{m-1}(x_i)$:

$$g_i = \frac{\partial L(y_i, a_i)}{\partial a_i}, \qquad h_i = \frac{\partial^2 L(y_i, a_i)}{\partial a_i^2}.$$

g_i описывает направление изменения потери; h_i — её кривизну. Производные фиксированы, пока строим текущее дерево.

2. Разбиваем признак на бины

Границы бинов задаём по train до обучения. **Гистограмма** в узле — таблица числа объектов и сумм по бинам:

$$G_b = \sum_{i \in b} g_i, \qquad H_b = \sum_{i \in b} h_i.$$

Пример. Восемь объектов, один признак; $h_i = 1$ для всех.

Бин	Значения x_i	Производные g_i	G_b	H_b
1	1, 2	2, 1	3	2
2	3, 4	1, 0	1	2
3	7, 8	−1, −1	−2	2
4	9, 10	−2, −2	−4	2

3. Проверяем границы между бинами

Четыре упорядоченных бина дают три варианта разбиения:

Порог	Бины слева	Бины справа	Gain
$x \le 2.5$	1	2, 3, 4	≈ 4.08
$x \le 5.5$	1, 2	3, 4	**6.25**
$x \le 8.5$	1, 2, 3	4	≈ 4.08

Для среднего варианта суммируем **верхние две строки** гистограммы для левого листа, **нижние две** — для правого:

Левый лист: $G_L = 4$, $H_L = 4$. **Правый:** $G_R = -6$, $H_R = 4$.
Родитель: $G = -2$, $H = 8$. Для каждого из трёх вариантов собираем суммы G и H и вычисляем Gain.

Что ускоряем? Вместо семи границ между значениями проверяем три границы бинов. По объектам проходим для сбора статистики; Gain считаем по готовым суммам.

4. Считаем выгоду разбиения: Gain

Ньютоновский критерий с L2 и штрафом за дополнительный лист:

$$\text{Gain} = \frac{1}{2}\left[\underbrace{\frac{G_L^2}{H_L + \lambda}}_{\text{левый лист}} + \underbrace{\frac{G_R^2}{H_R + \lambda}}_{\text{правый лист}} - \underbrace{\frac{(G_L + G_R)^2}{H_L + H_R + \lambda}}_{\text{родитель}}\right] - \gamma.$$

Два новых листа. Две отдельные поправки сравниваем с одной общей поправкой родителя. Формула дана без L1.
λ регулирует величины поправок в листьях (L2); γ штрафует дополнительный лист. G^2 — квадрат суммы первых производных, не вторая производная.
Для нашего порога при $\lambda = \gamma = 0$:

$$\text{Gain} = \frac{1}{2}\left(\frac{4^2}{4} + \frac{(-6)^2}{4} - \frac{(-2)^2}{8}\right) = 6.25.$$

Родитель одинаков для всех порогов одного узла. Его можно опустить при выборе порога, но нужно учесть, чтобы оценить само улучшение и решить, стоит ли делить узел.

5. GOSS: выборочная оценка Gain

Пусть n — число объектов во всей обучающей выборке. a — доля, сохраняемая по наибольшим $|g_i|$; b — доля, случайно выбираемая из остальных. **Обе доли считаем от всей выборки:** $|A| = an$, $|B| = bn$; $a + b \le 1$.
Пример: $n = 1000$, $a = 0.2$, $b = 0.1$. В A оставляем 200 объектов, в B случайно берём 100 из оставшихся 800. Вес каждого объекта из B равен $800/100 = 8$.
Gain считаем по всем объектам из A и B. Объекты из B учитываем с увеличенным весом c:

$$c = \frac{1-a}{b}, \qquad \widetilde{G}_S = \sum_{i \in A_S} g_i + c \sum_{i \in B_S} g_i.$$

A_S и B_S — объекты из групп A и B, попавшие в лист S. В LightGBM так же взвешиваем h_i: строим гистограммы по подвыборке и подставляем $\widetilde{G}, \widetilde{H}$ в критерий Gain.

Критерий из статьи: $\widetilde{V} = \frac{1}{n}\left(\frac{\widetilde{G}_L^2}{n_L} + \frac{\widetilde{G}_R^2}{n_R}\right)$.

Здесь n_L, n_R — числа объектов исходной выборки слева и справа. Без сэмплирования, при $h_i = 1$, $\lambda = \gamma = 0$, критерии V и Gain выбирают одинаковый порог. **Это не два последовательных расчёта.**

Источники: Ke et al., LightGBM (2017), §3; LightGBM: GOSS; LightGBM: критерий разбиения. Формула Gain выше записана в соглашениях XGBoost; масштабы и пороги в LightGBM отличаются.