LIME: что объясняем и что получаем

Исходная ситуация. Клиент зарабатывает 60 тыс. руб. Модель f предсказывает вероятность одобрения кредита 22%. Хотим понять: **как доход влияет на этот прогноз?**

Идея. Сложную модель f трудно объяснить целиком. Приблизим её ответы рядом с этим клиентом простой прямой g: её наклон покажет, как меняется прогноз с доходом. Эта прямая — *суррогатная модель*.

1. Посмотрим, как отвечает исходная модель

Сделаем две копии клиента: с доходом 50 и 70 тыс. руб. Возраст, число кредитов и остальные признаки сохраним. Подадим все три варианта в уже обученную f:

Доход, тыс. руб.	Прогноз f	Вес близости π
50	0,14	0,5
60	0,22	1
70	0,34	0,5

Обучаем g повторять прогнозы f. Фактические исходы кредитов здесь не нужны.

2. Зачем веса и откуда взялись 1 и 0,5

Точность рядом с доходом 60 тыс. важнее. Выберем простое правило: вес равен 1 в этой точке и уменьшается до 0 при отклонении на 20 тыс. руб.:

$$\pi(z) = \max\left(0,\ 1 - \frac{|z-60|}{20}\right), \qquad \pi(50) = 1 - \frac{10}{20} = 0{,}5.$$

Здесь z — доход в тыс. руб. Радиус 20 тыс. задаём сами. **Вес 0,5 означает: квадрат ошибки на этом варианте учитываем вдвое слабее**, чем на исходном клиенте.

3. Найдём простое правило g

Возьмём прямую $g(z) = b + w(z-60)$. Здесь b — её прогноз при доходе 60 тыс., а w — изменение прогноза при добавлении **одной тысячи рублей**.

Подбираем b и w, чтобы сумма квадратов ошибок с весами была минимальна:

$$\underbrace{0{,}5\,[0{,}14 - g(50)]^2}_{\text{клиент с доходом 50}} + \underbrace{[0{,}22 - g(60)]^2}_{\text{исходный клиент}} + \underbrace{0{,}5\,[0{,}34 - g(70)]^2}_{\text{клиент с доходом 70}} \longrightarrow \min.$$

Из-за симметрии доходов и весов решение имеет простой вид:

$$b = \frac{0{,}5 \cdot 0{,}14 + 1 \cdot 0{,}22 + 0{,}5 \cdot 0{,}34}{0{,}5 + 1 + 0{,}5} = 0{,}23, \qquad w = \frac{0{,}34 - 0{,}14}{70 - 50} = 0{,}01.$$

Получили $\boldsymbol{g(z) = 0{,}23 + 0{,}01(z - 60)}$. При доходах 50, 60 и 70 тыс. она выдаёт 0,13, 0,23 и 0,33 — близко к ответам f из таблицы.

4. Что в итоге узнали

Рядом с этим клиентом рост дохода на 10 тыс. руб. повышает прогноз модели примерно на 10 процентных пунктов: $0{,}01 \cdot 10 = 0{,}10$.

Мы получили понятное правило поведения f в этой окрестности. Исходный прогноз остаётся 22%; g его лишь объясняет. Для другого клиента наклон может быть иным.

В полном LIME варьируют несколько признаков. Здесь — один признак и регрессия без регуляризации. Объясняем поведение модели, не причинный эффект. Ribeiro et al., 2016.