Продвинутое машинное обучение

Лекция 7: Интерпретируемость: основные методы оценки важности признаков для ML моделей

Автор курса: Лапшина Анастасия (University of Maryland, College Park, ВШЭ)

НИУ ВШЭ 2026-2027

План лекции

1. Зачем нужна интерпретация.
   Три оси, по которым делят методы
2. Интерпретируемость по определению:
   линейные модели, наивный Байес, деревья
3. Графические методы:
   ICE, PDP, ALE
4. Числовые оценки важности:
   Permutation Importance, SHAP, LIME

Часть 1. Зачем нужна интерпретация

Интерпретируемость vs. Black box

Интерпретируемая по определению

Структура и параметры имеют математический смысл: коэффициент, правило, условная вероятность. Объяснение получается в комплекте с моделью, отдельные методы интерпретации могут оказаться избыточны.

Чёрный ящик

Нейросети, большие ансамбли, иногда бустинги. Структура слишком сложна, чтобы читать ее напрямую и понимать значение отдельных компонентов модели.

Объяснение строится отдельно, уже после обучения. Это post-hoc методы интерпретации.

Классификация методов интерпретации

Ante-hoc / Post-hoc

Ante-hoc – интерпретация заложена в структуру модели изначально.

Post-hoc – метод применяется уже после обучения, поверх готовой модели.

Локальная / Глобальная

Локальная – объяснение конкретного предсказания: почему модель так решила для этого объекта.

Глобальная – анализ модели в целом: какие признаки важны и как влияют в среднем.

Model-specific / Model-agnostic

Model-specific – метод предназначен для конкретного класса моделей.

Model-agnostic – универсальный метод, применим к любому чёрному ящику.

Что даёт интерпретация в предметной области

Медицина	Какие показатели здоровья привели к тому, что пациент отнесён в группу риска – врач может верифицировать и интерпретировать вывод модели.
Кредитный скоринг	Какие показатели привели к отказу клиенту в одобрении кредитной карты/повышении кредитного лимита
Найм	Какие показатели повысили вероятность найма при автоотборе по резюме – появляется возможность проверить эти показатели на предвзятость
Предиктивное обслуживание	Какие показатели привели к тому, что оборудование помечено как ломающееся. Зная это, сотрудник быстрее локализует и исправит проблему

Часть 2. Интерпретация по определению

Линейные модели и логистическая регрессия

Линейная регрессия и обобщённые линейные модели

$$y = \beta_0 + \beta_1 x_1 + \ldots + \beta_p x_p + \varepsilon$$

Каждый коэффициент β_j показывает изменение отклика y при увеличении признака x_j на единицу при прочих равных*.

Логистическая регрессия

$$\log \frac{P(y=1)}{P(y=0)} = \beta_0 + \beta_1 x_1 + \ldots + \beta_p x_p$$

Модель описывает логарифм отношения шансов, и β_j читается как вклад признака в изменение шансов. Это делает прозрачной и бинарную классификацию.

* При коррелированных признаках изменить один, не тронув остальные, невозможно. Буквальное чтение и интерпретация коэффициента перестают работать.

Логистическая регрессия

p = P(y = 1 | x) – вероятность класса 1 для объекта x; шансы (odds) = p / (1 − p)

1 **Модель**

$$\log \frac{p}{1-p} = \beta_0 + \beta_1 x_1 + \ldots + \beta_j x_j + \ldots + \beta_p x_p$$

2 **Два объекта, xj отличается на 1**

$$\log \text{odds}_2 = \beta_0 + \ldots + \beta_j (x_j + 1) + \ldots + \beta_p x_p$$

$$\log \text{odds}_1 = \beta_0 + \ldots + \beta_j x_j + \ldots + \beta_p x_p$$

3 **Вычитаем**

$$\log \text{odds}_2 - \log \text{odds}_1 = \beta_j \quad \Leftrightarrow \quad \log \frac{\text{odds}_2}{\text{odds}_1} = \beta_j$$

4 **Потенцируем**

$$\frac{\text{odds}_2}{\text{odds}_1} = e^{\beta_j} \quad \Rightarrow \quad \text{odds}_2 = \text{odds}_1 \cdot e^{\beta_j}$$

Признак прибавляет βj к логиту и умножает шансы в exp(βj) раз. Насколько при этом вырастет вероятность, зависит от исходного уровня p.

Наивный байесовский классификатор

$$P(y \mid x_1, \ldots, x_p) \propto P(y) \prod_{j=1}^{p} P(x_j \mid y)$$

Что означает

Каждое предсказание определяется априорной вероятностью класса P(y) и вкладом каждого признака x_j через условные вероятности $P(x_j \mid y)$. «Наивное» допущение независимости позволяет показать, какой именно фактор усиливает или ослабляет вероятность класса

Нюансы

Допущение независимости признаков почти всегда неверно на реальных данных. Модель остаётся полностью читаемой, но ее вероятности плохо откалиброваны. Поэтому наивный Байес хорош как объяснимый baseline и плох как источник вероятностей для принятия решений.

Решающие деревья: уровни интерпретации

Локально – маршрут по дереву

Дерево – иерархия правил вида «если–то», где на каждом шаге делается пороговое разбиение признака. Предсказание объясняется конкретным маршрутом от корня к листу и набором выполненных условий.

Глобально – важности признаков

Каждый узел строится как решение задачи уменьшения меры загрязненности. Насколько сильно узел её снизил – настолько признак в этом узле и важен. Суммируем по всем узлам, где признак использовался.

Важность признака в узле N_k:

$$I_k = w_k \cdot \mathrm{imp}_k - w_{\mathrm{left}(k)} \cdot \mathrm{imp}_{\mathrm{left}} - w_{\mathrm{right}(k)} \cdot \mathrm{imp}_{\mathrm{right}}$$

Индекс Джини или энтропия

Общая важность признака в дереве

– это сумма по всем узлам, где признак использовался, нормированная на суммарную важность всех признаков.

$$\mathrm{FI}(f) = \frac{\sum_{N_k \,:\, f_k = f} I_k}{\sum_j \sum_{N_k} I_k}$$

Что дает Feature Importance:

числовую шкалу, по которой признаки можно упорядочить и сравнить между собой. Это самая дешевая глобальная интерпретация из существующих, посчитанная внутри обученной модели и не требующая ни одного дополнительного вызова

Нюансы:

1) Смещение к признакам с большим числом уникальных значений.
2) Считается на обучающей выборке (могли переобучиться).
3) Есть коррелированные признаки.

Границы ante-hoc интерпретации

Мультиколлинеарность

Масштаб признаков

Размер модели



Post-hoc методы

Часть 3. Графические методы: ICE, PDP, ALE

Графические (plot-based) методы

ICE

Individual Conditional Expectation

Линия на каждый объект: как меняется его прогноз при изменении одного признака.

локальный

PDP

Partial Dependence Plot

Усреднённый ICE: как в среднем меняется прогноз модели при изменении признака.

глобальный

ALE

Accumulated Local Effects

Накопленный локальный эффект внутри узких интервалов значений признака.

глобальный

ICE: индивидуальное условное ожидание

Задача метода – оценить, как меняется прогноз модели с изменением одного признака для каждого объекта выборки.

n объектов, p признаков, сетка из m значений признака j (фиксируем его)

Вход: m копий выборки

X'_1	столбец j = j_1	n × p
X'_2	столбец j = j_2	n × p
⋮		
$X'_□$	столбец j = $j_□$	n × p

Стэк всех копий – (n · m) × p строк на входе модели

Выход: матрица прогнозов

n × m

	j_1	j_2	j_3	···	$j_□$	
объект 1	f_{11}	f_{12}	f_{13}	···	$f_{1□}$	**ICE-линия**
объект 2	f_{21}	f_{22}	f_{23}	···	$f_{2□}$	
⋮	⋮	⋮	⋮		⋮	
объект n	$f_{□1}$	$f_{□2}$	$f_{□3}$	···	$f_{□□}$	
среднее	PD_1	PD_2	PD_3	···	$PD_□$	**PDP**

Строка – ICE-линия одного объекта по m точкам. Среднее по столбцам – кривая PDP.

Каждая ячейка – один вызов модели: всего n · m прогнозов. Для n = 100 000 и сетки m = 50 это 5 миллионов, поэтому ICE считают на подвыборке.

ICE: прокат велосипедов

Модель предсказывает число прокатов. Изучаем признак «температура», сетка из m = 3 точек: 10, 20, 30.

Xtest – исходная выборка

n = 3 объекта, p = 3 признака

	темп.	влажн.	вых.
объект 1	12	0,8	нет
объект 2	25	0,4	да
объект 3	18	0,6	нет

→

X'_1 – копия выборки

температура у всех = 10

	темп.	влажн.	вых.
объект 1	**10**	0,8	нет
объект 2	**10**	0,4	да
объект 3	**10**	0,6	нет

Копий столько же, сколько точек сетки: три – с температурой 10, 20 и 30.

Подменяется только столбец температуры. Влажность и «выходной» у каждого объекта остаются своими.

Прогноз модели → матрица n × m

	t = 10	t = 20	t = 30	
объект 1	40	90	130	← ICE-линия объекта 1
объект 2	55	120	170	
объект 3	45	100	150	
среднее	46,7	103,3	150	← точки кривой PDP

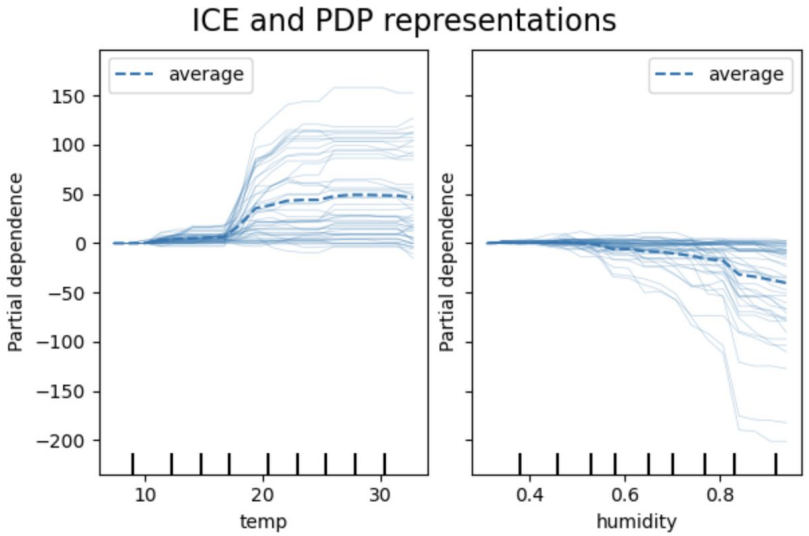
Как читать матрицу

Строка «объект 1» – это кривая: при 10 → 20 → 30 градусах прогноз идёт 40 → 90 → 130. Это одна ICE-линия, всего их n штук (для каждого объекта).

Нижняя строка – среднее по столбцам. Три её значения – это кривая PDP (partial dependence plot).

ICE и PDP на одном графике

Голубые линии – ICE по объектам, пунктир – их среднее (PDP)



Пологий PDP означает одно из двух:

1) признак не важен
2) эффекты разнонаправленны и взаимно погасились при усреднении.

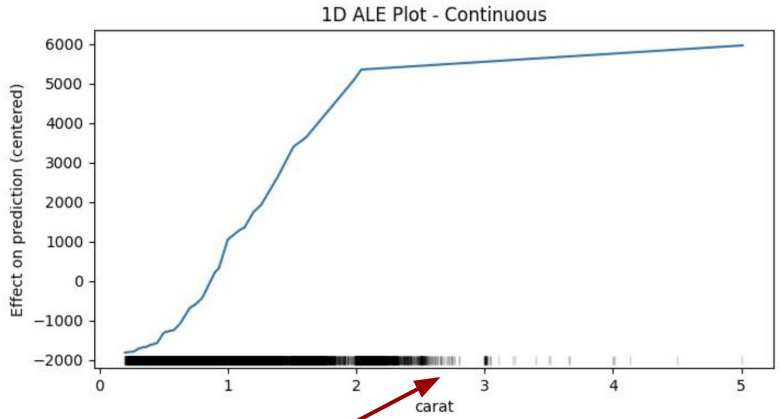
Различить эти два случая можно только по ICE.

ALE: накопленные локальные эффекты

Метод предложен как альтернатива PDP для случая мультиколлинеарных признаков.

Проблема PDP: подставляя значение признака всем объектам подряд, он спрашивает модель о комбинациях, которых в данных не бывает. ALE считает эффект только там, где данные действительно есть.

1. Выбираем интересующий признак F.
2. Делим диапазон его значений на интервалы.
3. Для каждого интервала возьмем нижнюю и верхнюю границы, посчитаем оба прогноза и усредним разницу по наблюдениям интервала.
4. Суммируем эффекты по интервалам и центрируем.



Чёрные штрихи внизу – плотность данных. После carat ≈ 2 наблюдений почти нет, и кривой там доверять не стоит

ICE, PDP, ALE – что использовать?

Метод	Уровень	Что показывает	Слабое место
ICE	локальный	По линии на каждый объект: как меняется именно его прогноз	На нескольких сотнях объектов график перестаёт читаться
PDP	глобальный	Среднюю кривую – усреднённый ICE по всей выборке	Среднее прячет разнонаправленные эффекты; экстраполяция
ALE	глобальный	Накопленный локальный эффект по интервалам значений	Нужен выбор числа интервалов; сложнее объяснить заказчику

Практический порядок использования

Сначала PDP, чтобы увидеть общую форму зависимости. Затем ICE поверх него, чтобы проверить, не прячет ли среднее разнонаправленные эффекты. И ALE вместо PDP там, где признаки заметно **скоррелированы**.

Часть 4. Оценки важности в числах: Permutation, SHAP, LIME

Permutation Importance

Если признак значим, случайная перестановка его значений сильно ухудшит качество модели

Постановка. Пусть a(x) – модель, обученная на множестве признаков F = {f_1, …, f_n}, а e_{orig} — её ошибка на тестовом наборе. Зафиксируем признак f_i.

1. Случайным образом переставим значения f_i в тестовом наборе данных.
2. Вычислим прогноз модели на данных с перестановкой.
3. Оценим ошибку модели на перетасованном наборе – e_{perm}.
4. Оценим важность признака как разность или как отношение ошибок.

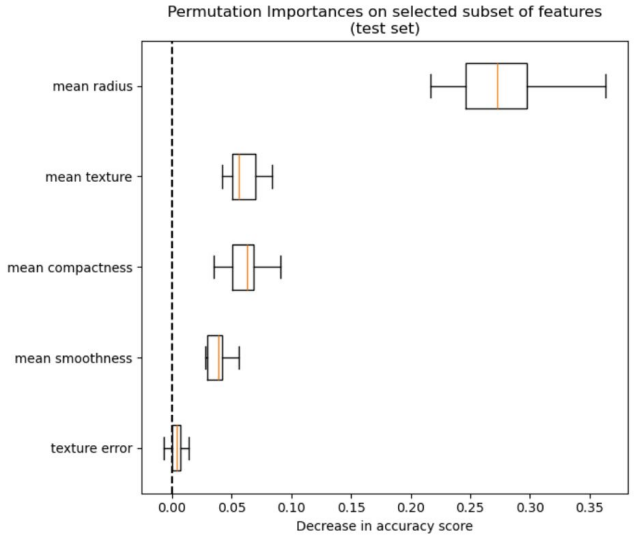
$$e_{\text{orig}} - e_{\text{perm}} \quad \text{или} \quad e_{\text{perm}} \,/\, e_{\text{orig}}$$

Итоговая важность признака – по K перестановкам:

$$\text{Importance}(f_i) = e_{\text{orig}} - \frac{1}{K}\sum_{k=1}^{K} e_{\text{perm},\,k}$$

Алгоритм повторяется для всех признаков, после чего они сортируются в порядке убывания важности.

Permutation Importance



Разброс = устойчивость

Узкий ящик с усами означает, что эффект перестановки воспроизводится от прогона к прогону. Широкий – что признак иногда важен, иногда нет, и решение о его удалении принимать рано.

Считать перестановочную важность нужно на отложенной выборке: на train она измеряет, насколько модель запомнила признак, а не насколько он ей полезен.

SHAP: значения Шепли (вектор Шепли)

Игроки – признаки, коалиция S – подмножество признаков, выигрыш v(S) – прогноз модели на этом подмножестве.

$$\mathrm{Sh}(v)_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!\,(n-|S|-1)!}{n!} \left[v(S \cup \{i\}) - v(S) \right]$$

Вклад признака i считается по следующему алгоритму:

1. Считаем прогноз v(S) без игрока i.
2. Добавляем i и считаем v(S ∪ {i}).
3. Берём разность – предельный вклад
4. Усредняем по всем коалициям с весами

Вес коалиции

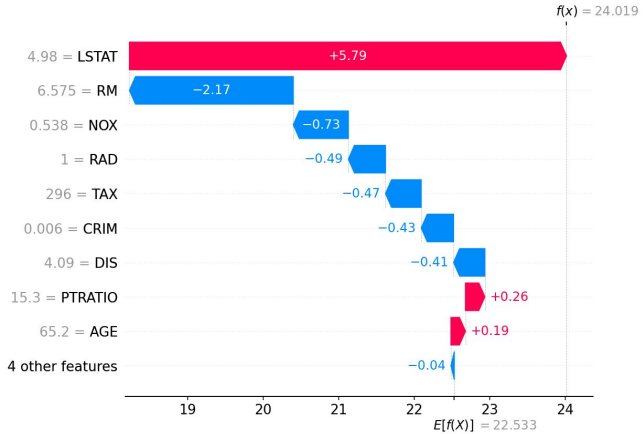
$$\frac{|S|!\,(n-|S|-1)!}{n!}$$

учитывает, сколькими способами коалиция S может сложиться до прихода игрока i

Сложность 2^n – перебор всех подмножеств

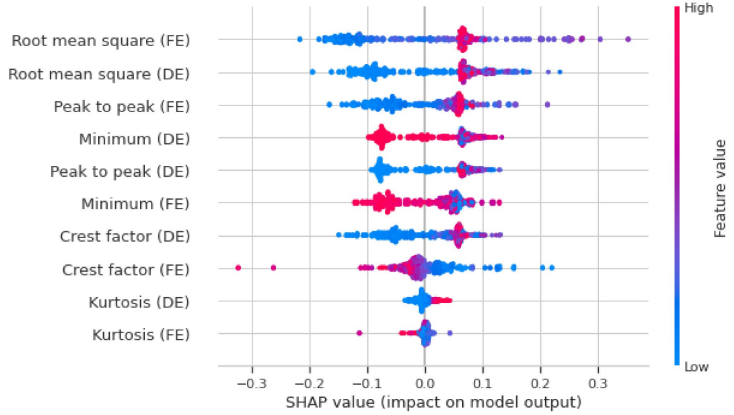
SHAP: читаем результат

Локально – один объект (waterfall)



Ось x содержит средний прогноз модели по выборке. Каждая полоса сдвигает прогноз на значение вклада признака (ось y), сумма сдвигов равна итоговому предсказанию для данного объекта

Глобально – вся выборка (beeswarm)



Точка – один объект. Признаки упорядочены по суммарному вкладу, цвет – значение самого признака (либо низкое, либо высокое): видно и силу влияния, и его направление (в какую сторону движется прогноз модели при уменьшении/увеличении значения признака).

LIME: локальная суррогатная модель

Простая модель g повторяет поведение сложной модели f в маленькой окрестности одного объекта x

$$\xi(x) = \arg\min_{g \in G}(L(f, g, \pi_x) + \Omega(g))$$

$L(f, g, \pi_x)$

взвешенная ошибка приближения: насколько g повторяет f рядом с x

π_x

вес объекта: чем ближе он к x, тем сильнее влияет на обучение g

$\Omega(g)$

штраф за сложность g. Как правило, ограничение на число признаков

Вокруг x порождают облако похожих объектов, спрашивают у ***f*** прогноз для каждого и обучают на этих парах взвешенную линейную модель. Её коэффициенты и есть объяснение – локальное, для одной точки.

LIME на примере: почему клиенту отказали

Объект x – возраст 47, доход 60 тыс., 3 действующих займа. Модель даёт вероятность одобрения займа 0,22

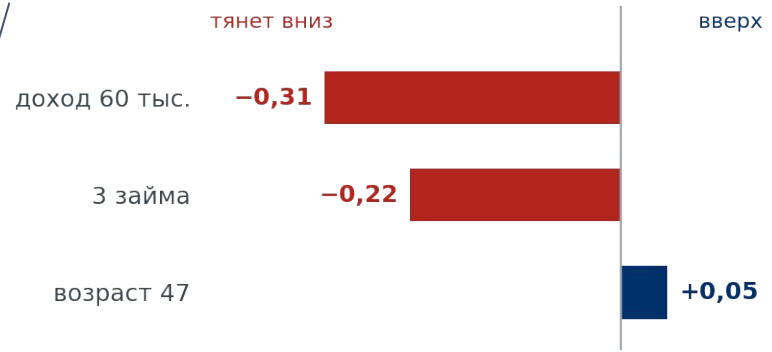
$$L(f, g, \pi_x) = \sum_z \pi_x(z)(f(z) - g(z'))^2$$

Облако вариантов вокруг клиента

вариант	доход	$f(z)$	$\pi_x(z)$
x – сам клиент	**60**	**0,22**	**1,00**
z_1	62	0,24	0,94
z_2	75	0,37	0,41
z_3	300	0,92	0,01

Всего 5 000 вариантов: у каждого подменен один признак. f(z) – вероятность одобрения от исходной модели, π(z) – вес варианта при обучении g: доход 62 тыс. почти как у клиента, доход 300 тыс. – уже другой человек.

Коэффициенты локальной модели g



Низкий доход и три займа тянут вероятность одобрения вниз, возраст немного вверх.

Коэффициенты локальные: они описывают поведение модели рядом с **этим** клиентом. У клиента с доходом 300 тысяч они были бы другими.

Источники

1. Molnar, C. — Interpretable Machine Learning, 2nd ed., 2022.
2. Goldstein, A. et al. — Peeking Inside the Black Box: Visualizing Statistical Learning with Plots of Individual Conditional Expectation, JCGS, 2015.
3. Apley, D., Zhu, J. — Visualizing the Effects of Predictor Variables in Black Box Supervised Learning Models, JRSS-B, 2020.
4. Fisher, A., Rudin, C., Dominici, F. — All Models Are Wrong, but Many Are Useful, JMLR, 2019.
5. Shapley, L. S. — A Value for n-Person Games, Contributions to the Theory of Games, 1953.
6. Lundberg, S., Lee, S.-I. — A Unified Approach to Interpreting Model Predictions, NeurIPS, 2017.
7. Lundberg, S. et al. — From Local Explanations to Global Understanding with Explainable AI for Trees, Nature Machine Intelligence, 2020.
8. Ribeiro, M., Singh, S., Guestrin, C. — «Why Should I Trust You?»: Explaining the Predictions of Any Classifier, KDD, 2016.
9. Rudin, C. — Stop Explaining Black Box Machine Learning Models for High Stakes Decisions, Nature Machine Intelligence, 2019.