Продвинутое машинное обучение

Лекция 8: Калибровка, неопределенность и выбор порога: метод Платта, изотоническая регрессия, ECE, пороги принятия решений

Автор курса: Лапшина Анастасия (University of Maryland, College Park, ВШЭ)

НИУ ВШЭ 2026-2027

Часть 1. Что такое калибровка

Определение

Модель откалибрована, если её оценка совпадает с реальной частотой положительного класса среди объектов с такой оценкой:

$$\mathbb{P}(y = 1 \mid \hat{s}(x) = s) = s \qquad \forall s \in [0, 1]$$

среди всех объектов, которым модель предсказала вероятность класса 1, равную s, доля объектов класса 1 должна быть равна s

Это утверждение о группе

Про один объект «правильная вероятность» непроверяема: мы видим только 0 или 1. Калибровка проверяется на выборке объектов с похожей оценкой.

Score ≠ вероятность

Выход sigmoid или доля голосов деревьев - это просто число от 0 до 1. Ничто не заставляет его быть частотой.

Когда это критично

Везде, где число идёт в решение: ожидаемая стоимость, скоринг, медицина, ставки. Если порядок важнее числа (рексис) - можно обойтись и без калибровки.

Калибровка и разделяющая способность

AUC зависит только от порядка объектов. Любое строго возрастающее преобразование оценок его не меняет:

$$\mathrm{AUC}(\hat{s}) = \mathrm{AUC}(\phi \circ \hat{s}) \quad \text{для любого возрастающего } \phi$$

=> по AUC нельзя судить о качестве вероятностей: можно возвести все оценки в квадрат, AUC не изменится, а калибровка сломается.

Две независимые оси качества

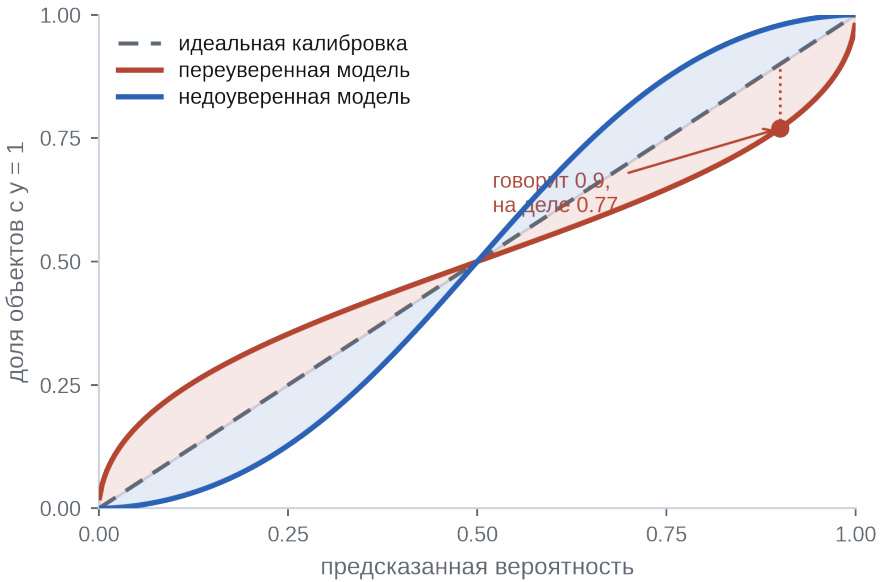
Разделение — умеет ли модель отличать классы
метрики: AUC, PR-AUC

Калибровка — честны ли сами числа
метрики: ECE, Brier, надёжность

Про калибровку разных моделей

- Логистическая регрессия — калибрована по построению
- Бустинг над деревьями — стягивает оценки к центру, кривая сигмоидная
- Случайный лес — усреднение голосов тоже уводит от 0 и 1
- Нейросети — обычно переуверенны
- SVM и naive Bayes — выход не является вероятностью

Диаграмма надёжности: как это выглядит



Оценки разбиваем на интервалы (бины), для каждой сравниваем среднюю оценку с реальной долей единиц.

Что изображено и что это значит

- Диагональ - идеал: сказанное совпадает с наблюдаемым
- Кривая ниже диагонали - модель переуверена: обещает больше, чем даёт
- Кривая выше - недоуверена: реальная частота выше заявленной

Что НЕ отражено в диаграмме

- Не видно, сколько объектов в каждом интервалы - крайние интервалы часто почти пусты
- Форма сильно зависит от числа и границ интервалов
- Поэтому рядом всегда стоит смотреть гистограмму распределения оценок

Часть 2. Как измерять калибровку: ECE, Brier, log loss

Expected Calibration Error

Сводим диаграмму надёжности в одно число: средний по бинам разрыв между заявленным и наблюдаемым.

$$\mathrm{ECE} = \sum_{m=1}^{M} \frac{|B_m|}{n} \left|\mathrm{acc}(B_m) - \mathrm{conf}(B_m)\right|$$

$$\mathrm{acc}(B_m) = \frac{1}{|B_m|} \sum_{i \in B_m} y_i \qquad \mathrm{conf}(B_m) = \frac{1}{|B_m|} \sum_{i \in B_m} \hat{s}_i$$

Как считается

- Делим [0,1] на M корзин (обычно 10–20)
- В каждой считаем среднюю оценку conf и реальную долю единиц acc
- Берём модуль разрыва и усредняем с весом по числу объектов
- MCE - то же, но максимум вместо среднего: худшая корзина

Почему ECE обманчив

- Зависит от разбиения: другое число корзин - другое значение
- Смещён вниз на малых выборках: в пустых корзинах разрыв не виден
- Сама оценка смещена: выборочный ECE систематически занижает истинный
- ECE = 0 достижим у бесполезной модели, выдающей всем базовую частоту

Собственные метрики: определение и проверка

Метрика S называется собственной, если в среднем эту метрику минимизирует именно истинная вероятность. Такую метрику нельзя улучшить, соврав в оценке:

$$q = \arg\min_p \mathbb{E}_{Y \sim \mathrm{Bern}(q)} [S(p, Y)]$$

Проверяем Brier

$$\mathbb{E}\left[(p - Y)^2\right] = q(1-p)^2 + (1-q)p^2$$

$$\frac{\partial}{\partial p} = -2q(1-p) + 2(1-q)p = 0 \Rightarrow p = q$$

Минимум ровно в p = q => метрика собственная.

Проверяем log loss

$$\mathbb{E}[S] = -q\log p - (1-q)\log(1-p)$$

$$\frac{\partial}{\partial p} = -\frac{q}{p} + \frac{1-q}{1-p} = 0 \Rightarrow p = q$$

Тот же ответ => тоже собственная.

А accuracy - не собственная accuracy: любое $p > t$ даёт тот же результат Поэтому по ней вероятности не оценивают.

Brier score и log loss: собственные метрики

Собственная метрика - такая метрика, при которой ожидаемый штраф минимален при честном ответе.

Brier score

$$\mathrm{BS} = \frac{1}{n}\sum_{i=1}^{n}(\hat{s}_i - y_i)^2$$

Квадратичная ошибка. Раскладывается на три части:

$$\mathrm{BS} = \mathrm{REL} - \mathrm{RES} + \mathrm{UNC}$$

- REL - калибровка, меньше лучше
- RES - разрешение оценок, больше лучше
- UNC - шум задачи, от модели не зависит

Log loss

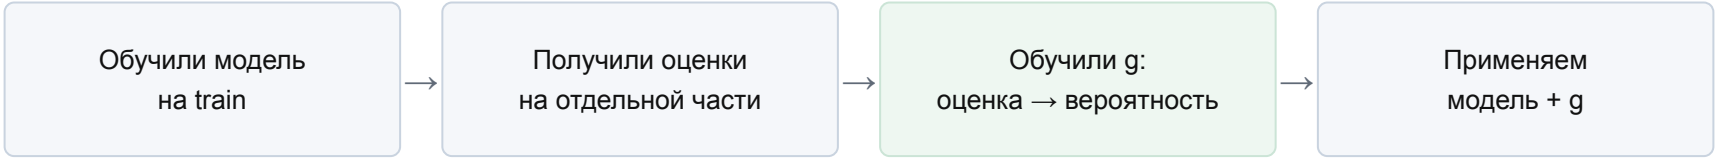
$$\mathrm{LL} = -\frac{1}{n}\sum_{i=1}^{n}[y_i \log \hat{s}_i + (1 - y_i)\log(1 - \hat{s}_i)]$$

- Тоже собственная метрика; её оптимизирует бустинг
- Сильнее Brier реагирует на слишком сильную уверенность
- Жёстко штрафует уверенные ошибки: 0.99 при y = 0

Часть 3. Методы калибровки: Платт, изотоническая, температура

Общая схема: учим монотонное отображение

Модель не переобучаем. Поверх её выхода ставим маленькую функцию g, переводящую оценку в вероятность:



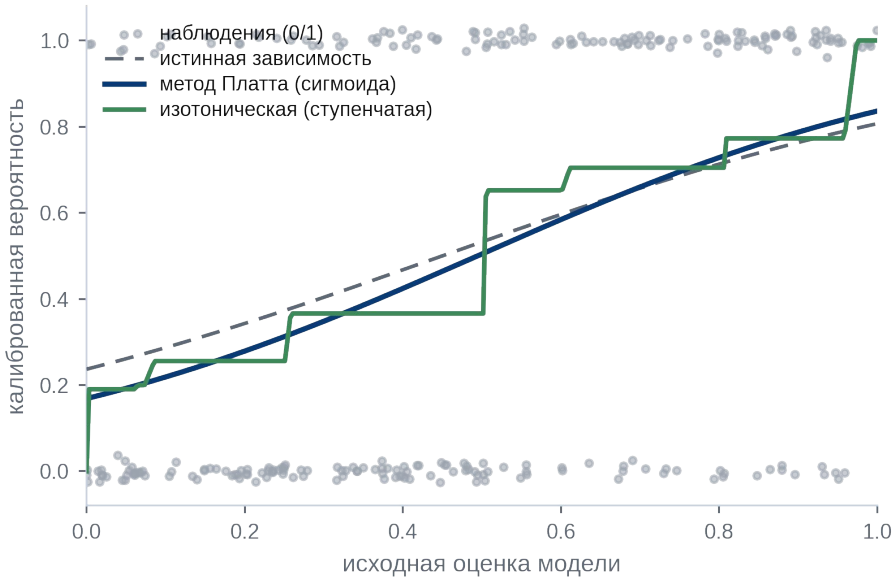
Главное правило: отдельные данные

- На train оценки модели оптимистичны и смещены
- Калибровка по train выучит поправку под переобучение
- Нужен отдельный набор или CalibratedClassifierCV с cv

Почему g обязана быть монотонной

- Монотонность не меняет порядок - AUC не портится
- Чиним шкалу, не трогая разделяющую способность
- Немонотонная g - это уже новая модель

Метод Платта и изотоническая регрессия



Сигмоида задаёт форму заранее, изотоническая подстраивается под данные.

Метод Платта

$$\hat{p}(x) = \sigma(A \cdot f(x) + B) = \frac{1}{1 + \exp(-(Af(x) + B))}$$

$$A, B = \arg\min \; -\sum_i [t_i \log \hat{p}_i + (1 - t_i) \log(1 - \hat{p}_i)]$$

Логрегрессия на одной переменной - самой оценке. Сглаженные таргеты t_i вместо 0/1 страхуют от переобучения.

Изотоническая регрессия

$$\min_{g \text{ неубыв.}} \sum_{i=1}^{n} (g(\hat{s}_i) - y_i)^2$$

Любая неубывающая функция с минимальной квадратичной ошибкой. Алгоритм PAVA, линейное время, ступенчатый результат.

Гибкость vs. Устойчивость

	Метод Платта	Beta-калибровка	Изотоническая
Форма отображения	сигмоида, задана заранее	гибкое семейство кривых	любая неубывающая, ступенчатая
Нужный объём данных	сотни объектов	сотни объектов	тысячи и больше
Ключевое свойство	не умеет вернуть тождество	содержит тождество	подстраивается под любую форму
Когда брать	мало данных, форма сигмоидная	разумный дефолт вместо Платта	много данных, сложная форма

$$\operatorname{logit} \hat{p} = c + a \log s - b \log(1 - s)$$

Beta-калибровка — логрегрессия на log s и log(1−s). В отличие от Платта, содержит тождество и потому не портит уже откалиброванную модель.

$$\hat{p} = \operatorname{softmax}(z / T)$$

Многоклассовый случай: one-vs-rest с нормировкой либо один параметр температуры на все логиты.

Дисбаланс классов ломает калибровку

Взвешивание классов, undersampling и SMOTE меняют базовую частоту. Модель честно учит вероятности для изменённой выборки — но не для реальности.

$$\frac{p}{1-p} = \frac{p_s}{1-p_s} \cdot \frac{\pi}{1-\pi} \cdot \frac{1-\pi_s}{\pi_s}$$

π — доля положительного класса в реальности, π_s — доля в обучающей выборке

Что происходит на практике

- Undersampling завышает вероятности
- class_weight даёт ровно тот же сдвиг
- AUC не падает - легко не заметить

Что с этим делать

- Проще всего не перевзвешивать вовсе
- А если пришлось, то откалибровать на реальной частоте (формула выше как быстрый запасной вариант)

Часть 4. Неопределённость: чего не говорит одна вероятность

Алеаторная и эпистемическая неопределённость

Неопределённость в точке x раскладывают по параметрам модели θ — то есть по членам ансамбля:

$$\mathrm{Var}(y \mid x) = \underbrace{\mathbb{E}_\theta[\mathrm{Var}(y \mid x, \theta)]}_{\text{алеаторная}} + \underbrace{\mathrm{Var}_\theta(\mathbb{E}[y \mid x, \theta])}_{\text{эпистемическая}}$$

Алеаторная — шум самой задачи

- Одинаковые признаки, разные исходы — так устроен мир
- Не уменьшается с ростом данных
- Именно её и оценивает калиброванная вероятность

Эпистемическая — незнание модели

- Модель мало видела таких объектов и не знает, что сказать
- Уменьшается с ростом данных
- p = 0.5 значит и «монетка», и «понятия не имею»

Практические способы оценить неопределенность

Ансамбли и бутстрап

- Обучаем K моделей на разных подвыборках
- Среднее — прогноз, разброс — мера незнания
- Дорого: K обучений вместо одного

Conformal prediction

- Вместо числа выдаем множество исходов
- Гарантия покрытия почти без предположений
- Дёшево: нужен лишь калибровочный набор

Отказ от ответа*

- Разброс велик — передаём человеку
- Метрики: качество на принятых и доля отказов
- Часто самое честное решение в проде

* Отказ от ответа - это тоже решение, а любое решение упирается в порог. О том, откуда порог берётся, поговорим в след. части

Conformal prediction: как это устроено

Метод выдаёт множество исходов с гарантией покрытия (почти без предположений).

1 Нонконформити-скор

$$s_i = 1 - \hat{p}(y_i \mid x_i)$$

На калибровочной выборке считаем, насколько модель «не согласна» с истинным ответом.

2 Квантиль

$$\hat{q} = \text{квантиль уровня } \frac{\lceil (n+1)(1-\alpha) \rceil}{n} \text{ набора } \{s_i\}$$

Берём эмпирический квантиль этих значений с поправкой на конечную выборку.

3 Множество

$$C_\alpha(x) = \{y : 1 - \hat{p}(y \mid x) \le \hat{q}\}$$

В ответ включаем все исходы, чей скор не превышает найденный порог.

$$\mathbb{P}(y \in C_\alpha(x)) \ge 1 - \alpha$$

Что именно гарантировано

- Покрытие в среднем по объектам, а не для каждого
- Гарантия не зависит от качества модели
- Плохая модель даст широкие множества

Как это выглядит в продакшн

- Модерация: одна метка — сами, две и больше — к человеку
- Медицина: множество диагнозов вместо одного
- Размер множества или ширина интервала — сигнал для отказа от автоматического решения

Часть 5. Пороги принятия решений

Порог выводится из стоимости ошибок

Действие a = 1 выгодно, если его ожидаемая стоимость меньше стоимости бездействия:

$$\mathbb{E}[\text{cost}] = \hat{p}\,(1-a)\,C_{\text{FN}} + (1-\hat{p})\,a\,C_{\text{FP}}$$

Приравняв стоимости двух действий, получаем правило и сам порог:

$$a = 1 \iff \hat{p}(x) > t^*$$

$$t^* = \frac{C_{\text{FP}}}{C_{\text{FP}} + C_{\text{FN}}}$$

Как интерпретировать формулу

- Порог задается стоимостями, а не данными
- Дорогой пропуск - низкий порог, ловим больше
- Дорогая ложная тревога - порог выше

$$C_{\text{FN}} = 9\,C_{\text{FP}} \;\Rightarrow\; t^* = 0.1$$

Почему порог 0.5 - почти всегда неверно

- 0.5 оптимален лишь при равной цене ошибок
- Порог 0.5 означает, что ложная тревога и пропуск обходятся одинаково дорого, но это часто не так - можем упустить больных пациентов

Формула верна для калиброванных вероятностей. На некалиброванных оценках порог теряет интерпретацию и подбирается эмпирически.

Вывод порога и пример из антифрода

Сравниваем ожидаемую стоимость двух действий при калиброванной вероятности p:

$$\mathbb{E}[\text{cost} \mid a=1] = (1-p)\,C_{\text{FP}}$$

ошибочно сработали, если y = 0

$$\mathbb{E}[\text{cost} \mid a=0] = p\,C_{\text{FN}}$$

пропустили цель, если y = 1

Действуем, когда первое меньше второго и раскрываем скобки:

$$(1-p)\,C_{\text{FP}} < p\,C_{\text{FN}} \quad \Rightarrow \quad C_{\text{FP}} < p(C_{\text{FN}} + C_{\text{FP}}) \quad \Rightarrow \quad t^* = \frac{C_{\text{FP}}}{C_{\text{FP}} + C_{\text{FN}}}$$

Антифрод: посчитаем порог

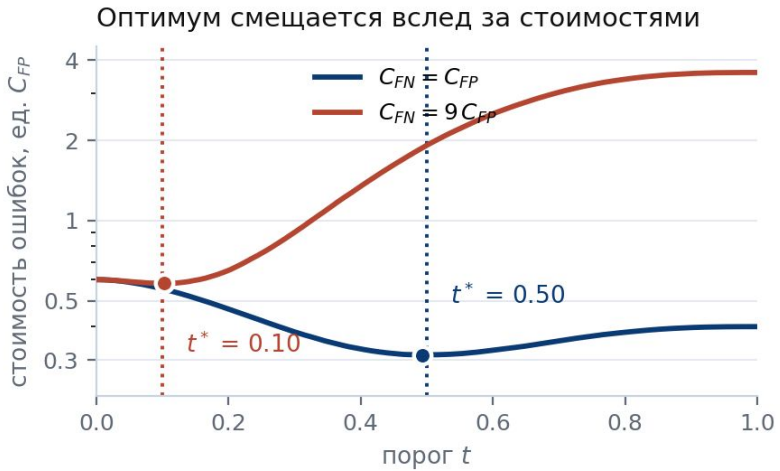
- Ручная проверка заявки - около 50 ₽
- Пропущенный чарджбэк - около 5000 ₽

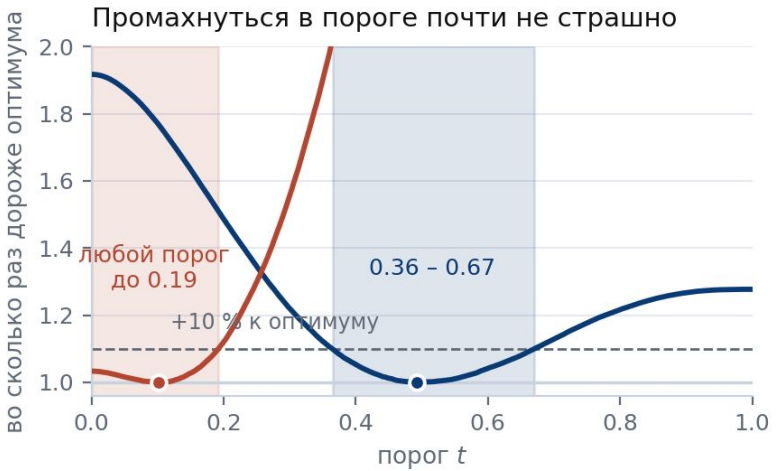
$$t^* = \frac{50}{50 + 5000} \approx 0.01$$

Что из этого следует

- Проверяем всё выше 1%, а не выше 50%
- Стоимости изменились - пересчитали порог
- Работает только на калиброванных p

Стоимость как функция порога





Точки - минимум эмпирической кривой, пунктир - теоретический t* из формулы. Они совпадают.

Слева: где оптимум

Стоимости диктуют порог: 0.50 → 0.10 при цене 9 : 1

Справа: чем грозит промах

- В затененной зоне переплата не больше 10 %
- Ошибка в оценке стоимостей намного дороже, чем неточность в выборе порога

Discover Weekly: 30 треков, **всегда** 30

Порог считать мы умеем. Но плейлист обновляется по понедельникам и всегда (10 лет) ровно на 30 треков





Порог держит качество, но не объём

- Тихая неделя — порог прошли 8 треков, релизы — 90
- В плейлист всё равно пойдёт 30: порог бессилен

Поэтому давайте фиксировать k, а не порог

- Объем (k) фиксирован, а порог (как следствие) — это p 30-го трека

* Зачем тогда вероятности: ранги не перемножить, а p(лайк) × p(дослушает) - можно. И сумма p по 30 трекам отвечает, увеличить ли плейлист до 50.

Калибровка по группам и справедливость

Первое требование - потребуем калибровку внутри каждой группы:

$$\mathbb{P}(y = 1 \mid \hat{s} = s,\ G = g) = s \qquad \forall g$$

Второе требование - равные доли ошибок у групп:

$$\mathrm{TPR}_a = \mathrm{TPR}_b, \qquad \mathrm{FPR}_a = \mathrm{FPR}_b$$

Их нельзя выполнить одновременно

- При разных базовых частотах оба критерия несовместимы
- Исключения вырожденные: равные частоты или идеал

Что это значит на практике

- Калиброванный по группам балл даст разные FPR
- Вопрос о справедливости - это вопрос о выборе критерия
- Решение принимается вне модели

$$\pi_a \neq \pi_b \ \Rightarrow\ \text{совместить нельзя}$$

То есть, еще раз, что делать?

Минимальный пайплайн:

1. Отложили калибровочную часть → 2. Обучили g на её оценках → 3. Проверили, что стало лучше → 4. Посчитали порог из стоимостей

Псевдокод

- `CalibratedClassifierCV(base, method=…, cv=5)`
- `calibration_curve(y, p, n_bins=10, strategy='quantile')`
- `brier_score_loss(y, p)` — до и после

Как понять, что калибровка удалась

- Brier и ECE упали, а AUC не изменился
- Кривая надёжности легла на диагональ
- Если AUC просел, то где-то потеряли монотонность

Источники

1. Platt, J. (1999). “Probabilistic Outputs for Support Vector Machines and Comparisons to Regularized Likelihood Methods.” Advances in Large Margin Classifiers.
2. Zadrozny, B., Elkan, C. (2002). “Transforming Classifier Scores into Accurate Multiclass Probability Estimates.” KDD.
3. Niculescu-Mizil, A., Caruana, R. (2005). “Predicting Good Probabilities with Supervised Learning.” ICML.
4. Guo, C. et al. (2017). “On Calibration of Modern Neural Networks.” ICML — temperature scaling.
5. Naeini, M. P., Cooper, G., Hauskrecht, M. (2015). “Obtaining Well Calibrated Probabilities Using Bayesian Binning.” AAAI — ECE.
6. Angelopoulos, A. N., Bates, S. (2023). “Conformal Prediction: A Gentle Introduction.” Foundations and Trends in ML.