

Курс "Продвинутое машинное обучение", ОП "Магистр по наукам о данных"
2 курс магистратуры, 1 модуль — 8 недель: 8 лекций и 8 семинаров

Теоретико-практический курс с акцентом на понимание устройства ключевых алгоритмов
машинного обучения

Аннотация	Курс продолжает базовый курс машинного обучения и посвящён тому, как модели устроены изнутри: почему они работают, при каких условиях ломаются и как это проверить экспериментально. На лекциях разбираются надёжность ML-экспериментов и утечки данных, решающие деревья CART, бэггинг и случайный лес, градиентный бустинг как функциональный градиентный спуск, современные реализации GBDT, подбор гиперпараметров, калибровка вероятностей и выбор порога принятия решений, интерпретируемость выходов моделей. Практика построена вокруг вычислительных экспериментов: на семинарах студенты воспроизводят разобранные свойства методов на данных, сравнивают алгоритмы между собой и объясняют причины полученных результатов. Домашние задания выполняются в формате ноутбуков Jupyter и предполагают собой работу с реальными датасетами, чтобы применить полученные знания на практике. Курс будет полезен для перехода от применения готовых библиотек к осознанному выбору, настройке и корректной оценке моделей.
Цели освоения курса	1. Знать устройство корректного ML-эксперимента: эмпирический и популяционный риск, схемы валидации, источники утечек данных. 2. Знать разложение ошибки на смещение и дисперсию и его связь со сложностью модели. 3. Уметь строить и настраивать решающие деревья CART, включая критерии разбиения и апостериорную обрезку. 4. Знать принципы бэггинга, Random Forest и ExtraTrees и уметь получать ООВ-оценку качества. 5. Знать градиентный бустинг как функциональный градиентный спуск и уметь выводить псевдоостатки и значения листьев. 6. Уметь применять современные реализации GBDT (XGBoost, LightGBM, CatBoost) и строить пайплайны кодирования признаков без утечки таргета. 7. Уметь подбирать гиперпараметры случайным и байесовским поиском, применять Hyperband/ASHA и early stopping, вести трекинг экспериментов. 8. Уметь интерпретировать модели с помощью SHAP, PDP и ICE и понимать ограничения этих методов. 9. Уметь оценивать и исправлять калибровку вероятностей и выбирать порог принятия решений под заданную функцию потерь.
Планируемые результаты обучения	Студент, освоивший курс: 1. различает эмпирический и популяционный (ожидаемый) риск и выбирает подходящую схему валидации; 2. диагностирует утечки данных и объясняет роль смещения, дисперсии и отбора

	модели; 3. объясняет построение CART, критерии разбиения и апостериорную обрезку дерева; 4. объясняет снижение дисперсии в Bagging, Random Forest и ExtraTrees и строит ООВ-оценку; 5. интерпретирует градиентный бустинг как функциональный градиентный спуск и выводит формулы псевдоостатков и значений листьев; 6. сравнивает XGBoost, LightGBM и CatBoost и строит пайплайны признаков без утечки таргета; 7. подбирает гиперпараметры, применяет регуляризацию и ведёт историю экспериментов; 8. оценивает калибровку вероятностей и выбирает порог с учётом функции потерь; 9. применяет SHAP, PDP и ICE с учётом ограничений этих методов;
Пререквизиты курса	Базовый курс машинного обучения: обучение с учителем, основные функции потерь и метрики качества, переобучение и регуляризация, линейные модели. Программирование на Python и опыт работы с NumPy, pandas и scikit-learn. Из математики: линейная алгебра, математический анализ (градиент, производная сложной функции), теория вероятностей и математическая статистика.
Технические требования	Персональный компьютер. Домашние задания выдаются и сдаются в формате ноутбуков Jupyter (.ipynb); отдельные задания также могут предусматривать сдачу модулей Python (.py).

Понедельный план курса

№	Тема лекции	Тема семинара	Кто готовит?
1	Надёжность ML-экспериментов: эмпирический и популяционный риск, схемы валидации, bias-variance trade-off и утечки данных	Воспроизводимая оценка качества: holdout и k-fold, поиск утечек, эффект выбора лучшей модели	Преподаватель курса
2	CART: меры нечистоты, поиск разбиений,	Обучение и диагностика CART: критерии, глубина,	Преподаватель курса

	апостериорная обрезка, oblique trees	cost-complexity pruning и устойчивость разбиений	
3	Bagging, Random Forest и ExtraTrees: снижение дисперсии, рандомизация и OOB-оценка	Сравнение ансамблей деревьев: ручная OOB-оценка, число деревьев, max_features и важность признаков	Преподаватель курса
4	Gradient Boosting: аддитивная модель и функциональный градиентный спуск	Пошаговое построение бустинга: псевдоостатки, значения листьев и влияние learning rate	Преподаватель курса
5	Современные GBDT и feature engineering: Taylor- и Newton-boosting, XGBoost, LightGBM, CatBoost, target encoding, пайплайны	Сравнение GBDT-библиотек; OOF target encoding, конструирование признаков и сборка пайплайнов	Преподаватель курса
6	НПО и регуляризация: случайный и байесовский поиск, Hyperband/ASHA, early stopping, трекинг экспериментов	Поиск гиперпараметров в Optuna, контроль переобучения и трекинг экспериментов	Преподаватель курса
7	Интерпретируемость: основные методы оценки важности признаков для ML моделей	Разбор SHAP, PDP и ICE	
8	Калибровка, неопределённость и выбор порога: метод Платта, изотоническая регрессия, ECE, пороги принятия решений	Калибровочные кривые, Brier score и ECE; методы Платта и изотоническая регрессия; выбор порога	Преподаватель курса

Практика и контроль

Форма контроля	Содержание	Кто готовит? Когда выдаётся / проходит?
Промежуточные тесты — 2 работы (ПТ1 и ПТ2)	Два индивидуальных теста на понимание определений, формул, допущений методов и интерпретацию результатов. Тесты проводятся в электронной форме, каждый оценивается по 10-балльной шкале. Вклад в итоговую оценку — 10% от каждого из тестов ПТ1 и ПТ2.	Преподаватель курса. Тесты выдаются после лекций №4 и 7 и включают в себя вопросы исключительно по уже пройденному материалу. Срок выполнения каждого теста — 25 минут в начале лекции. Отдельная пересдача теста не проводится.
Домашнее задание 1 — Деревья Решений	Индивидуальный ноутбук Jupyter (.ipynb) и модуль Python (.py): исследование решающих деревьев и переобучения, реализация дерева классификации с нуля и анализ bias–variance decomposition и бэггинга. Оцениваются корректность реализации, экспериментов и обоснованность выводов. Максимальная оценка — 10 баллов.	Преподаватель курса. Выдаётся после лекции № 3, срок выполнения — 2 недели. Штрафы за нарушение срока сдачи — см. раздел «Формула оценки и пересдачи». Отдельная пересдача домашнего задания не проводится.
Домашнее задание 2 — Бустинг	Индивидуальный ноутбук Jupyter (.ipynb) и модуль Python (.py): реализация градиентного бустинга и его ключевых механизмов, работа с XGBoost/LightGBM/CatBoost и анализ качества модели. Оцениваются корректность реализации, экспериментов и обоснованность выводов. Максимальная оценка — 10 баллов.	Преподаватель курса. Выдаётся после лекции № 5, срок выполнения — 2 недели. Штрафы за нарушение срока сдачи — см. раздел «Формула оценки и пересдачи». Отдельная пересдача домашнего задания не проводится.
Домашнее задание 3 —	Индивидуальный ноутбук Jupyter (.ipynb): сравнение методов	Преподаватель курса. Выдаётся после лекции № 7,

Основные методы оценки важности признаков для ML моделей	интерпретации моделей и оценки важности признаков, включая ICE/PDP/ALE, permutation importance, SHAP и LIME, с анализом глобальных и локальных объяснений. Оцениваются корректность применения методов и обоснованность интерпретаций. Максимальная оценка — 10 баллов.	срок выполнения — 1 неделя. Штрафы за нарушение срока сдачи — см. раздел «Формула оценки и пересдачи». Отдельная пересдача домашнего задания не проводится.
Бонусные задания на лекциях и семинарах	Часть лекций и семинаров включают в себя бонусные задания. Бонусные задания не образуют отдельной формы контроля: полученные за них баллы добавляются к оценкам за домашние задания и промежуточные тесты по правилам, описанным в разделе «Формула оценки и пересдачи». Выполнение бонусных заданий не является обязательным.	Преподаватель курса. Выдаются на семинарах в течение модуля; сроки сдачи объявляются на соответствующем семинаре.
Финальный экзамен (ФЭ)	Индивидуальный экзамен по материалу всех восьми тем курса. Состоит из двух частей: тестовой части и устной части, которую студент сдаёт преподавателю. Пользоваться любыми справочными материалами в ходе экзамена запрещено. После ответа студенту могут быть заданы дополнительные вопросы по программе курса, а также предложены задачи на понимание теоретического материала; такие задачи не требуют проведения обширных вычислений. Оценка за экзамен выставляется по 10-балльной шкале на основании общего впечатления преподавателя от ответа студента. Вклад в итоговую оценку — 30%.	Преподаватель курса. Проводится дистанционно в экзаменационный период по расписанию образовательной программы.
Пересдача	Проводится дистанционно в том же формате, что и экзамен: тестовая часть и	Преподаватель курса. Сроки определяются расписанием

	ответы на устные вопросы преподавателю. Пользоваться материалами запрещено. Пересдаётся только экзаменационная часть; оценки за домашние задания и промежуточные тесты не изменяются.	образовательной программы.
--	--	----------------------------

Формула оценки и пересдачи

Итоговая оценка за курс вычисляется по формуле:

Итог = Округление($0,5 \times ДЗ + 0,1 \times ПТ1 + 0,1 \times ПТ2 + 0,3 \times ФЭ$),

где ДЗ — средняя арифметическая оценка за три домашних задания, ПТ1 — оценка за первый промежуточный тест, ПТ2 - оценка за второй промежуточный тест, ФЭ — оценка за финальный экзамен. Все составляющие оцениваются по 10-балльной шкале. Округление арифметическое.

Блокирующие формы контроля

Блокирующие формы контроля в курсе отсутствуют. При этом финальный экзамен даёт 30% итоговой оценки, поэтому студент, не сдающий экзамен, получает ФЭ = 0, и его итоговая оценка не может превышать 7 баллов из 10.

Бонусные баллы

Бонусные баллы, полученные за ответы на вопросы на лекциях и/или выполнение дополнительных заданий на семинарах, суммируются за весь модуль и распределяются равномерно. Сначала они добавляются к оценкам за домашние задания — равными долями к каждому из трёх ДЗ, при этом оценка за отдельное домашнее задание не может превысить 10 баллов. Если после этого у студента остаются нераспределённые бонусные баллы, а оценка ДЗ уже максимальна, остаток равномерно добавляется к оценкам за промежуточные тесты — равными долями к каждому из двух тестов, при этом оценка за отдельный тест также не может превысить 10 баллов. Баллы, оставшиеся после заполнения обеих составляющих до максимума, не учитываются.

Штрафы за нарушение срока сдачи домашних заданий

Просрочка менее 24 часов — оценка за работу умножается на 0,7.

Просрочка от 24 до 48 часов — оценка за работу умножается на 0,5.

Просрочка 48 часов и более — работа не принимается и оценивается в 0 баллов.

Автомат

Автомат ставится тогда и только тогда, когда одновременно выполнены следующие условия: $ПТ1 \geq 6$ и $ПТ2 \geq 6$ и $ДЗ \geq 6$. Студент, удовлетворяющий всем трем условиям, может отказаться от сдачи финального экзамена и получить в качестве итоговой накопленную оценку:

Накоп = $\min(7; \text{Округление}((0,5 \times ДЗ + 0,1 \times ПТ1 + 0,1 \times ПТ2) / 0,7))$.

Таким образом, итоговая оценка по автомату не может быть ниже 6 и не может превышать 7 баллов из 10. Критерии выставления автомата одинаковы для всех студентов курса и не варьируются между группами.

Пересдачи

Пересдача домашних заданий предусмотрена, если у студента есть уважительная причина, по которой одно или несколько домашних заданий не было сдано. Формат пересдачи совпадает с обычным форматом сдачи домашних заданий курса. Пересдача тестов по уважительной причине предусмотрена в устном формате преподавателю курса и может включать в себя вопросы и задания, отличные от вопросов, которые были в соответствующем тесте.

Первая пересдача проводится дистанционно в формате, аналогичном экзамену: тестовая часть и ответы на устные вопросы преподавателю. Она представляет собой пересдачу экзаменационной части, формула итоговой оценки не меняется; оценки за домашние задания и промежуточные тесты не пересматриваются.

Вторая пересдача (с комиссией) проводится дистанционно в том же формате. Формула итоговой оценки не меняется.

Литература

Рекомендуемая основная литература

1. Hastie T., Tibshirani R., Friedman J. The Elements of Statistical Learning: Data Mining, Inference, and Prediction. 2nd ed. Springer, 2009.
2. James G., Witten D., Hastie T., Tibshirani R., Taylor J. An Introduction to Statistical Learning with Applications in Python. Springer, 2023.
3. Murphy K. P. Probabilistic Machine Learning: An Introduction. MIT Press, 2022.

Рекомендуемая дополнительная литература

1. Breiman L. Random Forests // Machine Learning. 2001. Vol. 45. P. 5–32.
2. Friedman J. H. Greedy Function Approximation: A Gradient Boosting Machine // The Annals of Statistics. 2001. Vol. 29, № 5. P. 1189–1232.
3. Chen T., Guestrin C. XGBoost: A Scalable Tree Boosting System // KDD, 2016.
4. Ke G. et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree // NeurIPS, 2017.

5. Prokhorenkova L. et al. CatBoost: Unbiased Boosting with Categorical Features // NeurIPS, 2018.
6. Niculescu-Mizil A., Caruana R. Predicting Good Probabilities with Supervised Learning // ICML, 2005.
7. Lundberg S. M., Lee S.-I. A Unified Approach to Interpreting Model Predictions // NeurIPS, 2017.
8. Molnar C. Interpretable Machine Learning: A Guide for Making Black Box Models Explainable. 2nd ed., 2022.